



PROGETTO 1 - Batch Processing

Sistemi ed Architetture per Big Data

Simone Ercole - 0360105

Federico Pepe - 0365363

Anno Accademico 2025 - 2026

Roadmap



ARCHITETTURA
SISTEMA




QUERY




ANALISI
PRESTAZIONALE

Architettura Pipeline



Architettura Pipeline - Apache NiFi

- In merito ai dati:
 - Sono state scartate le colonne non necessarie.
 - Sono stati raggruppati per mese.
 - Sono stati salvati in HDFS nel formato Avro.



Architettura Pipeline - Apache Spark

- ▶ Architettura Stand-Alone con un solo nodo Master ed n Worker (variati negli esperimenti).
- ▶ Viene eseguito il pre-processamento dei dati:
 - ▶ Controllo dei valori *Null*, nelle **colonne fondamentali** per le successive query analitiche.
 - ▶ Controlli di coerenza sui ritardi (*ARR_DELAY* e *DEP_DELAY*)
 - ▶ Gestione delle cause di ritardo, in conformità con l'ente regolatore statunitense per l'aviazione civile (FAA).

Architettura Pipeline - Apache Spark

- ▶ Le query sono state implementate con la libreria **PySpark**.
- ▶ Tecnologie ed approcci utilizzati:
 - ▶ **API Spark DataFrame**.
 - ▶ **API Spark RDD**, nello specifico:
 - ▶ Approccio basato sulla classe **PySpark Row**.
 - ▶ Approccio basato sulle *tuple* **Python**.

Roadmap



ARCHITETTURA
SISTEMA



QUERY




ANALISI
PRESTAZIONALE


Query 1

- Facendo riferimento al dataset dei voli relativi alle compagnie aeree AA (*American Airlines*) e DL (*Delta*), calcolare la media, il massimo ed il minimo del ritardo in partenza (*DEP_DELAY*) ed il rate di cancellazione dei voli (*CANCELLATION_RATE*) per ciascun mese. Nell'analisi del ritardo in partenza si considerino esclusivamente i voli non cancellati.

Query 1 - Dataframe



Query 1 - RDD (Row & Tuple)




Query 1 - Risultati


Mese	Airline	Media	Minimo	Massimo	Tasso Cancellazione
1	AA	12.89	-34.0	3298.0	3.73
1	DL	12.83	-30.0	1209.0	2.80
2	AA	13.28	-27.0	3403.0	1.32
2	DL	11.35	-30.0	1222.0	0.23
3	AA	15.85	-27.0	3288.0	1.52
3	DL	10.32	-32.0	1176.0	0.49
4	AA	15.96	-28.0	2595.0	1.43
4	DL	8.71	-30.0	1145.0	0.51

Query 1 - Risultati

Andamento Percentuale Voli Cancellati- Compagnie American Airlines e Delta



Andamento Ritardo Medio Partenza - Compagnie American Airlines e Delta




Query 2


- ▶ Per ciascuna compagnia (*OP_UNIQUE_CARRIER*), calcolare il numero totale di voli non cancellati (*CANCELLED*) e non deviati (*DIVERTED*), il valore medio di ritardo in arrivo (*ARR_DELAY*) ed il valore medio delle componenti di ritardo:
 - ▶ *CARRIER_DELAY*
 - ▶ *WEATHER_DELAY*
 - ▶ *NAS_DELAY*
 - ▶ *SECURITY_DELAY*
 - ▶ *LATE_AIRCRAFT_DELAY*

Si considerino solo le compagnie con almeno 500 voli. Infine calcolare la classifica delle prime dieci compagnie ordinate per ritardo medio d'arrivo decrescente.

Query 2 - Dataframe



Query 2 - RDD (Row & Tuple)




Query 2 - Risultati


Airline	N° Voli	Media	Carrier	Weather	Nas	Security	Late Aircraft
OH	78476	17.16	7.24	1.66	3.31	0.03	12.13
F9	65965	11.32	5.92	0.49	3.95	0.00	10.42
G4	42596	9.54	5.68	2.04	4.27	0.16	7.54
AA	302790	8.98	5.95	1.01	2.97	0.02	7.41
OO	259692	7.59	7.93	2.47	2.68	0.02	3.38
B6	75680	6.14	4.49	0.43	4.31	0.03	7.08
HA	25707	5.81	4.46	0.54	0.10	0.02	3.29
MQ	87416	5.32	3.09	1.55	3.06	0.02	5.15
DL	312503	4.19	5.87	0.89	2.79	0.01	4.06
UA	248433	2.46	3.39	0.61	3.83	0.00	4.48

Query 2 - Risultati

Top10 Compagnie Per Ritardo Medio Di Arrivo




Incidenza Media Delle Cause Di Ritardo Per Le Top10 Compagnie




Query 3

- ▶ Facendo riferimento al dataset dei voli relativi alle compagnie aeree AA (*American Airlines*), DL (*Delta*), UA (*United*), e WN (*Southwest*), aggregare i dati di ciascuna compagnia sulle 24 ore della giornata. L'ora del giorno deve essere ricavata a partire dal campo *CRS_DEP_TIME*, considerando le 24 fasce orarie giornaliere.
- ▶ Per ciascuna compagnia e per ciascuna fascia oraria, considerando i valori di *DEP_DELAY* dei voli non cancellati calcolare:
 - ▶ 25° Percentile
 - ▶ 50° Percentile (Mediana)
 - ▶ 75° Percentile
 - ▶ 90° Percentile
- ▶ Inoltre, per ogni compagnia, calcolare il valore minimo e massimo del ritardo in partenza *DEP_DELAY* sull'intero dataset.

Query 3 - Dataframe




Query 3 - RDD (Row & Tuple)




Query 3 - Risultati

25°Percentile - Confronto tra Compagnie




50°Percentile - Confronto tra Compagnie




Query 3 - Risultati

75°Percentile - Confronto tra Compagnie



90°Percentile - Confronto tra Compagnie



Query 3 - Risultati

Airline	Minimo	Massimo
AA	-34.0	3403.0
DL	-32.0	1222.0
UA	-50.0	1349.0
WN	-24.0	721.0

Roadmap



ARCHITETTURA
SISTEMA



QUERY



ANALISI
PRESTAZIONALE

Analisi Prestazionali - Metodologia

- ▶ Valutazione sperimentale dei tempi di processamento delle query e confrontare dell'efficienza delle API offerte da Apache Spark: l'API **DataFrame** e **RDD**.
- ▶ Configurazione **Apache Spark**:
 - ▶ **Nodi Worker**:
 - ▶ Core: 2
 - ▶ Memoria RAM: 2Gbyte
 - ▶ Configurazione variabile: da 1 fino ad massimo di 3 nodi.
- ▶ **Replicazione degli esperimenti**:
 - ▶ Ciascuna query è stata eseguita un numero $n = 10$ iterazioni.
- ▶ **Criteri di misurazione**:
 - ▶ Tramite la funzione *time.time()*, campionati i tempi antecedenti la lettura dei dati in formato .Parquet e subito dopo la scrittura finale.
- ▶ **Sono stati calcolati i seguenti indicatori**:
 - ▶ Media e Deviazione standard campionaria
 - ▶ Intervallo di confidenza al 95%

Analisi Prestazionali - Query 1

Tecnica	Metrica	1 Worker	2 Worker	3 Worker
Dataframe	Media (s)	2.983	3.324	4.022
	CI 95%	2.983 ± 3.373	3.324 ± 4.126	4.022 ± 4.890
RDD (Row)	Media (s)	12.454	14.825	13.672
	CI 95%	12.454 ± 3.124	14.825 ± 4.268	13.672 ± 5.731
RDD (tuple)	Media (s)	11.335	10.846	11.645
	CI 95%	11.335 ± 3.298	10.846 ± 3.162	11.645 ± 3.334

Analisi Prestazionali - Query 2

Tecnica	Metrica	1 Worker	2 Worker	3 Worker
Dataframe	Media (s)	2.803	3.879	4.223
	CI 95%	2.803 ± 3.139	3.879 ± 4.446	4.223 ± 5.548
RDD (Row)	Media (s)	19.299	22.592	22.079
	CI 95%	19.299 ± 3.286	22.592 ± 4.925	22.079 ± 4.968
RDD (tuple)	Media (s)	12.729	12.920	13.373
	CI 95%	12.729 ± 1.870	12.920 ± 3.323	13.373 ± 3.141

Analisi Prestazionali - Query 3

Tecnica	Metrica	1 Worker	2 Worker	3 Worker
Dataframe	Media (s)	6.507	7.732	8.379
	CI 95%	6.507 ± 4.036	7.732 ± 5.475	8.379 ± 5.741
RDD (Row)	Media (s)	42.642	43.475	34.507
	CI 95%	42.642 ± 3.023	43.475 ± 6.014	34.507 ± 6.874
RDD (tuple)	Media (s)	32.458	24.958	26.478
	CI 95%	32.458 ± 1.927	24.958 ± 3.538	26.478 ± 4.097

Take-Away Message

► Catalyst Optimizer

- L'API strutturata basata su DataFrame si conferma la scelta architetturale ottimale. Grazie alle ottimizzazioni del Catalyst Optimizer, si riesce a garantire tempi di esecuzione a regime drasticamente inferiori rispetto alle controparti RDD.

► Ottimizzazione RDD

- L'uso di oggetti Row genera gravi colli di bottiglia dovuti alla continua serializzazione tra JVM e Python. La conversione dei record in Tuple native, rappresenta una strategia cruciale per abbattere i tempi di esecuzione e ridurre l'overhead.

► Limiti della scalabilità orizzontale

- L'aumento dei worker (da 1 a 3) non ha prodotto lo speed-up teorico a causa dei costi di scheduling e coordinamento su moli di dati contenute, dimostrando la necessità di dimensionare il cluster in base al reale volume dei dati.



Grazie per l'Attenzione !

Simone Ercole

Federico Pepe